Carlos Bonetti¹

¹Bacharelando de Ciência da Computação Departamento de Informática e Estatística Centro Tecnológico Universidade Federal de Santa Catarina

Orientação: Profa. Dra. Carina F. Dorneles

Trabalho de Conclusão de Curso, 2016/2

Introdução

Histórico e Justificativa

- AGUIAR, Felipe Nedel de; COSTA, Maria Eloísa. SILQ -**Sistema de Integração Lattes Qualis**. Trabalho de Conclusão de Curso. Florianópolis: UFSC, 2015.
- Lattes / Qualis
- Estratos de qualidade
- Avaliação de Programas
- Qualificação automática de produções científicas através de busca por similaridade textual nos dados Qualis:



Conceitos



Histórico e Justificativa

Introdução



Figura: Primeira versão do SILQ (http://silq.inf.ufsc.br)

Carlos Bonetti

Universidade Federal de Santa Catarina

Introdução

IR e Data Matching

- Information Retrieval (IR)
 - query
 - documentos
- Data-Matching
 - similaridade / dissimilaridade
 - threshold
 - n-grams / trigrams

Introdução •00

IR e Data Matching

- Information Retrieval (IR)
 - query
 - documentos
- Data-Matching
 - similaridade / dissimilaridade
 - threshold
 - ► n-grams / trigrams

```
"Revista": A = \{ \_R, \_Re, Rev, evi, vis, ist, sta, ta_\}
```

"Revisor":
$$B = \{_R, _Re, Rev, evi, vis, iso, sor, or_\}$$

trigrams(Revista, Revisão) =
$$\frac{|A \cap B|}{|A \cup B|} = \frac{5}{11} = 0.45 = 45\%$$

Introdução 000

Como o SILQ avalia um currículo Lattes

Trabalho #1 (extraído do Lattes)

Título: A Strategy for Allowing Meaningful and Comparable

Scores in Approximate Matching

Ano: 2007

Area: Ciência da Computação

Evento: Conference on Information and Knowledge Management

(CIKM)

Introdução ○○ ○●○

Como o SILQ avalia um currículo Lattes

Trabalho #1 (extraído do Lattes)

Título: A Strategy for Allowing Meaningful and Comparable

Scores in Approximate Matching

Ano: 2007

Área: Ciência da Computação

Evento: Conference on Information and Knowledge Management

(CIKM)

query: (título do evento, área)

 $q_T =$ (Conference on Information and Knowledge

Management (CIKM), Ciência da Computação)

Introdução

 $q_T =$ (Conference on Information and Knowledge Management (CIKM), Ciência da Computação)

Carlos Bonetti

 $q_T =$ (Conference on Information and Knowledge Management (CIKM), Ciência da Computação)

Conceito	Similaridade	Título	
A1	0.71	International Conference on Information and	
		Knowledge Management	
B4	0.64	International Conference on Information, Pro-	
		cess, and Knowledge Management	

Tabela: Resultados retornados pelo SILQ para a query q_T

Resultado

Trabalho #1 recebe o conceito A1

Motivação

- Atualização tecnológica e da base de dados
 - ▶ Qualis trienal → anual
 - Atualização da base de dados Qualis no SILQ
 - Considerar ano na query
- Qual o threshold ideal para o SILQ?
- Qual a taxa de acerto do sistema? Ele está avaliando corretamente os currículos Lattes?
- É possível aumentar a taxa de acerto utilizando feedback de usuários?

Objetivos

Objetivo geral

Objetivos

Analisar o impacto que o uso de feedback de relevância tem na precisão dos resultados de avaliações realizadas pelo SILQ, efetuado sobre uma nova arquitetura da ferramenta que inclui a criação de API de integração com outros sistemas e a atualização da base de dados conforme as novas classificações Qualis.

- 1. Reestruturação da arquitetura e banco de dados do SILQ a fim de suportar classificações de eventos e periódicos disponibilizados em um ritmo anual;
- 2. Atualização do banco de dados do sistema com as últimas classificações disponibilizadas pelo Qualis (anos 2013 e 2014);

- 1. Reestruturação da arquitetura e banco de dados do SILQ a fim de suportar classificações de eventos e periódicos disponibilizados em um ritmo anual;
- 2. Atualização do banco de dados do sistema com as últimas classificações disponibilizadas pelo Qualis (anos 2013 e 2014);
- 3. Criação de uma API pública de disponibilização dos serviços do SILQ, via camada de aplicação REST para integração com outros sistemas:

4. Alterações na interface do sistema incluindo migração de framework de interface, inclusão de controles de feedback, novos gráficos de acompanhamento de grupos de pesquisa e melhorias gerais de usabilidade;

- 4. Alterações na interface do sistema incluindo migração de framework de interface, inclusão de controles de feedback, novos gráficos de acompanhamento de grupos de pesquisa e melhorias gerais de usabilidade;
- 5. Propor novos algoritmos de avaliação baseados em similaridade textual e feedback de relevância e verificar se a taxa de acerto do sistema foi melhorada com tal ação.

Feedback de relevância

- Característica de sistemas IR
- Utilização de dados do usuário para melhorar sua precisão
- Explícito / Implícito

Métricas e avaliação de sistemas de IR

- Como saber se o sistema retorna os resultados corretos?
- Avaliação baseado em métricas
- ► Taxa de acerto (accuracy / exatidão*)

Extração e inserção dos novos dados Qualis

- Até final de 2015
 - Qualis trienal
 - **2010-2012**
 - PDFs e planilhas XLS
- Início de 2016
 - Qualis anual
 - **2010**, 2011, 2012, 2013, 2014
 - Planilhas CSV
- Limpeza manual (erros de codificação, ISSNs omitidos, etc.)
- 339.204 registros

Atualização tecnológica

- Criação da camada REST de integração
 - API pública de acesso aos dados Qualis e serviços do SILQ
- ► Migração de framework: Play → Spring
- Reescrita do front-end com AngularJS
 - Novos gráficos de avaliação para grupos de pesquisa
 - Melhorias no módulo de usuários
 - Remodelagem da página de resultados de avaliação
 - Inclusão dos controles de feedback
- Garantida da qualidade com testes automatizados

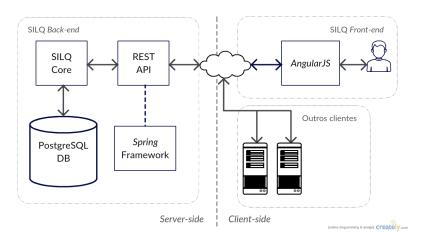


Figura: Nova arquitetura do SILQ

Introdução Objetivos

Alterações tecnológicas

Nome Trabalhos 60 registros Download .csv Carina Friedrich Dorneles Área do conhecimento Ciência da Computação 2016 | A Filtered-Page Ranking: An Approach for Previously Filtered HTML Documents Ranking ٠. Especialidade International Conference on Internet and Web Applications and Services Banco de Dados 83 100% 2012 ICIW International Conference on Internet and Web Applications and Services & Área utilizada na avaliação 2012 ISWSA International Conference on Intelligent Semantic Web-Services and Applications Ciência da Computação A1 70% 2012 MobiSvs International Conference on Mobile Systems, Applications, and Services 100 Período de avaliação 2012 ICWS IEEE International Conference on Web Services 16 Todos 2012 ICNS International conference on Networking and Services & Totalizador Nível de confiança: Normal Ver menos resultados A Conceito Otde. 2015 | Towards Automatic Document Classification by Exploiting only Knowledge Resources ٠. International Conference of the Chilean Computer Science Society A1 4 BB 100% 2012 SCCC International Conference of the Chilean Computer Science Society 6 A2 2 Ver mais resultados ♥ В1 3 **B2** 2015 | Implementação de um esquema de extração de dados tabulares da web **O** + XII Workshop de Trabalhos de Iniciação Científica (WTIC) В3 Nenhum conceito encontrado | Sugerir matching R4 2014 | Nazca: A Context-based Matching Method for Searching Heterogeneous Structures ٠. **B5** International Conference on Computer and Information Technology c 81 100% 2012 CIT International Conference on Computer and Information Technology 10 Ver mais resultados ♥

Figura: Nova página de avaliação do SILQ

2014 | Uso de Expressões Temporais em Busca na Web: Uma análise através das sugestões de consulta.

Escola Regional de Banco de Dados Nenhum conceito encontrado | Sugerir matching Ф÷

Obtenção de feedback



Figura: Controles de feedback da página de resultados de avaliação do SILQ

Carlos Bonetti

Algoritmos

- ▶ De que forma utilizar o *feedback* obtido?
- Criação de algoritmos baseados no trigrams do SILQ 1
 - ▶ fb(t)
 - query_aliasing
- Avaliação experimental

tivos Cono O OO

Uso de feedback de relevância

Algoritmo fb(1)

 $q_1 =$ ("Software Engineering Knowledge Engineering", 2009, CCO)

Carlos Bonetti

Algoritmo fb(1)

 $q_1 =$ ("Software Engineering Knowledge Engineering", 2009, CCO)

#	Evento	Similaridade
1	Software Engineering and Data Engineering (SEDE)	0.53
2	International Conference on Software Engineering and Knowledge Engineering (SEKE)	0.49

Algoritmo fb(1)

 $q_1 =$ ("Software Engineering Knowledge Engineering", 2009, CCO)

#	Evento	Similaridade
1	Software Engineering and Data Engineering (SEDE)	0.53
2	International Conference on Software Engineering and Knowledge Engineering (SEKE)	0.49

feedback 1: (ID Qualis, query)

 $f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})$

Algoritmo fb(1)

$$f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})$$

$$q_2 =$$
 ("Software Engineering Knowledge Engineering", 2010, CCO)

Carlos Bonetti

Algoritmo fb(1)

 $f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})$

 $q_2 =$ ("Software Engineering Knowledge Engineering", 2010, CCO)

#	Evento	Similaridade
2	International Conference on Software Enginee-	0.49
	ring and Knowledge Engineering (SEKE)	
1	Software Engineering and Data Engineering (SEDE)	0.53

 f_1 utilizado, *match* realizado com evento #2

Algoritmo fb(1)

 $f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})$

 $q_3 =$ ("Software Engineering and Knowledge Engineering", 2011, CCO)

Algoritmo fb(1)

 $f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})$

 $q_3 =$ ("Software Engineering and Knowledge Engineering", 2011, CCO)

- Feedback 1 não é considerado
- ▶ fb(1) considera somente *queries* idênticas
- ▶ fb(t): Considerar também feedbacks com queries similares!
 - t: threshold de similaridade de feedback

Desenvolvimento 0000000000000

Algoritmo fb(t)

```
f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})
```

 $q_3 =$ ("Software Engineering and Knowledge Engineering", 2011, CCO)

Similaridade: 0.88 (trigrams)

Algoritmo fb(t)

 $f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})$

 $q_3 =$ ("Software Engineering and Knowledge Engineering", 2011, CCO)

Similaridade: 0.88 (trigrams)

Considerando fb(0.75):

#	Evento	Similaridade
2	International Conference on Software Enginee-	0.49
	ring and Knowledge Engineering (SEKE)	
1	Software Engineering and Data Engineering (SEDE)	0.53

Carlos Bonetti

Algoritmo fb(t)

- 1. Cria o rank inicial de resultados utilizando a função trigrams (idêntico ao SILQ 1)
- 2. Pesquisa pelo feedback anterior mais similar à query submetida e cuja similaridade seja t ou superior
- 3. Caso exista, adiciona o Qualis atribuído ao feedback na primeira posição do rank

Algoritmo fb(t)

- Qual o valor de t ideal?
- Desconsidera os valores de similaridade do rank inicial
- Rank não é mais ordenado por similaridade

Carlos Bonetti

Algoritmo query_aliasing

```
f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})
```

 $q_4 =$ ("Software Engineering and Knowledge Engineering", 2011, CCO)

Similaridade: 0.88 (trigrams)

00000000000000

Algoritmo query_aliasing

 $f_1 = (\#2, \text{ "Software Engineering Knowledge Engineering"})$

 $q_4 =$ ("Software Engineering and Knowledge Engineering", 2011, CCO)

Similaridade: 0.88 (trigrams)

#	Evento	Rank
2		0.88
	ring and Knowledge Engineering (SEKE)	
1	Software Engineering and Data Engineering	0.53
	(SEDE)	

Uso de feedback de relevância

Algoritmo query_aliasing

- 1. Cria o rank inicial de resultados utilizando a função trigrams (idêntico ao SILQ 1)
- 2. Pesquisa pelo feedback anterior mais similar à query submetida
- 3. Caso exista, adiciona o Qualis atribuído ao feedback na lista de resultados com valor de rank igual ao valor de similaridade entre a nova query e a query do feedback

Avaliação experimental

- Conjunto de testes
 - 33 currículos de pesquisadores do PPGCC
 - 300 trabalhos aleatoriamente selecionados e avaliados manualmente
- Comparação entre o resultado retornado pelo sistema e o resultado selecionado

Avaliação de threshold ideal

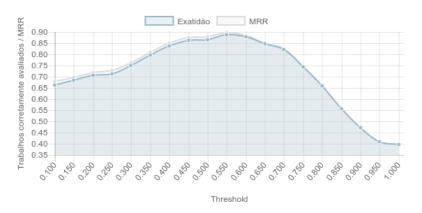


Figura: Valores de exatidão e MRR para diferentes valores de threshold utilizando o método trigram

Carlos Bonetti Universidade Federal de Santa Catarina

Exatidão dos algoritmos propostos

Algoritmo	Exatidão
trgm	88.667%
trgm + fb(1.00)	89.667%
trgm + fb(0.90)	90.667%
trgm + fb(0.80)	92.667%
trgm + fb(0.70)	92.667%
trgm + fb(0.60)	91.000%
$trgm + query_aliasing$	93.333%

Tabela: Comparação da exatidão dos diferentes algoritmos testados (utilizando threshold de 0.55)

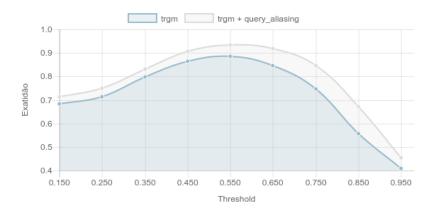


Figura: Comparação da taxa de acerto do algoritmo *trgm* e do *trgm* + *query_aliasing* para diferentes *thresholds*

Carlos Bonetti

- Criação da camada REST de integração
 - Ex.: http://silq.inf.ufsc.br/api/qualis

Carlos Bonetti

- Criação da camada REST de integração
 - Ex.: http://silq.inf.ufsc.br/api/qualis
- Atualização da base de dados com os novos registros Qualis

Carlos Bonetti

- Criação da camada REST de integração
 - Ex.: http://silq.inf.ufsc.br/api/qualis
- Atualização da base de dados com os novos registros Qualis
- Métricas de exatidão do sistema

- Criação da camada REST de integração
 - Ex.: http://silq.inf.ufsc.br/api/qualis
- Atualização da base de dados com os novos registros Qualis
- Métricas de exatidão do sistema
- Descoberto threshold ideal: 0.55

- Criação da camada REST de integração
 - Ex.: http://silq.inf.ufsc.br/api/qualis
- Atualização da base de dados com os novos registros Qualis
- Métricas de exatidão do sistema
- Descoberto threshold ideal: 0.55
- Inserção dos controles de feedback de relevância

- Criação da camada REST de integração
 - Ex.: http://silq.inf.ufsc.br/api/qualis
- Atualização da base de dados com os novos registros Qualis
- Métricas de exatidão do sistema
- Descoberto threshold ideal: 0.55
- Inserção dos controles de feedback de relevância
- ► Taxa de acerto média do sistema melhorada de 87% para 93.3% com o uso de *feedback* de usuários e query_aliasing

- Criação da camada REST de integração
 - Ex.: http://silq.inf.ufsc.br/api/qualis
- Atualização da base de dados com os novos registros Qualis
- Métricas de exatidão do sistema
- Descoberto threshold ideal: 0.55
- Inserção dos controles de feedback de relevância
- ► Taxa de acerto média do sistema melhorada de 87% para 93.3% com o uso de *feedback* de usuários e query_aliasing
- ▶ SILQ 2: http://silq.inf.ufsc.br

Avaliar outras funções de similaridade

- Avaliar outras funções de similaridade
- Avaliar diferentes estratégias de uso de feedback de relevância
 - Ex.: Algoritmo de Rocchio, machine learning, etc.

- Avaliar outras funções de similaridade
- Avaliar diferentes estratégias de uso de feedback de relevância
 - Ex.: Algoritmo de Rocchio, machine learning, etc.
- Tradução de nomes de eventos

- Avaliar outras funções de similaridade
- Avaliar diferentes estratégias de uso de feedback de relevância
 - Ex.: Algoritmo de Rocchio, machine learning, etc
- Tradução de nomes de eventos
- Automatizar ainda mais o processo de avaliação de Programas de Pós-Graduação conforme regras da CAPES
 - ► Gerar valores de *I_{geral}* e *I_{restrito}*
 - Utilizar pesos considerados pela CAPES

Análise do uso de *feedback* de relevância no Sistema de Integração Lattes-Qualis (SILQ)

Obrigado!

Carlos Bonetti carlosbonetti.mail@gmail.com